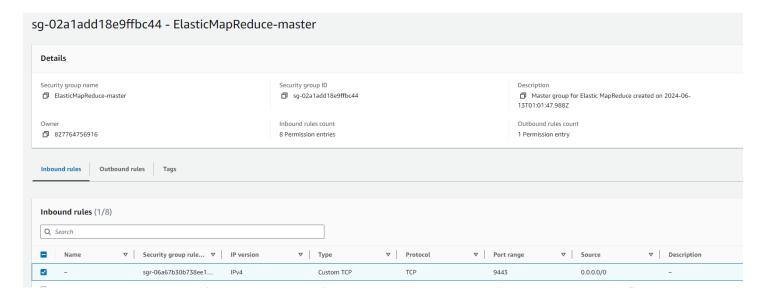
Health Department inspection results – Jupyter: Pyspark

Script:



health_violations.py

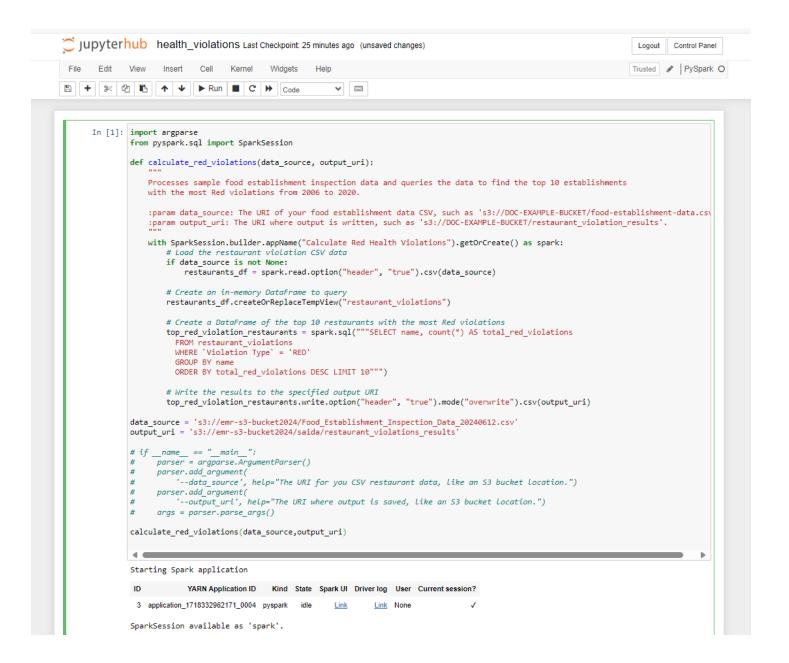
 Antes de dar início a atividade, precisamos fazer alterações nas configurações do EC2 para conseguir acessar nosso cluster (EC2) liberando os acessos vindo pela porta = '9443', Protocolo e Tipo = TCP Personalizado, Versão de IP = IPv4. Dessa forma, o Jupyter conseguirá acessar no cluster e realizar o processamento de dados pelo Spark.

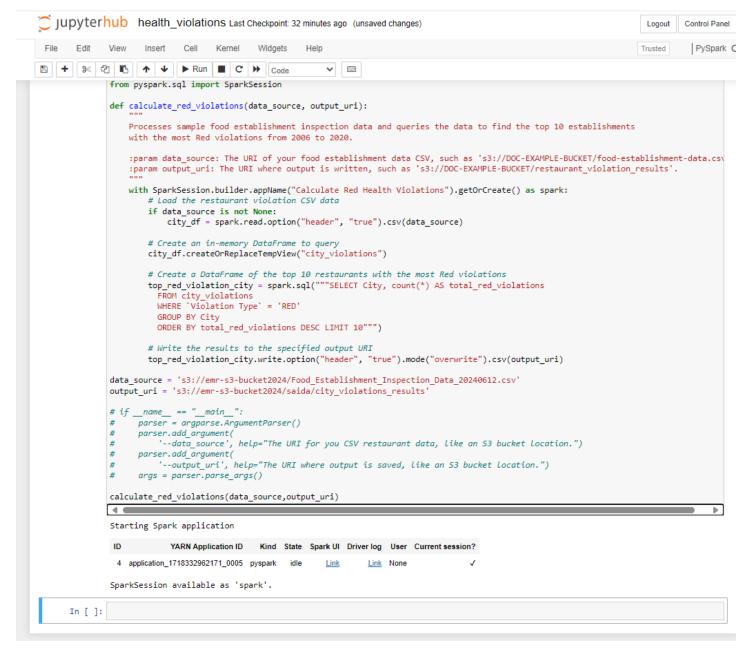


- 2. Ao finalizar a configuração de rede, retornando as propriedades do cluster, acessando a tab 'aplicativos' encontramos a URL da JupyterHub. Podemos ver que no final da URL, consta o número da porta que foi liberado o acesso e garantindo que conseguimos acessar o app.
- 3. Ao abrir o JyputerHub, criamos um Pyspark script (em anexo no início da atividade) para calcular os seguintes:
 - a. Análise de top 10 estabelecimentos com violação tipo RED
 - b. Análise de top 10 cidades com violação tipo RED

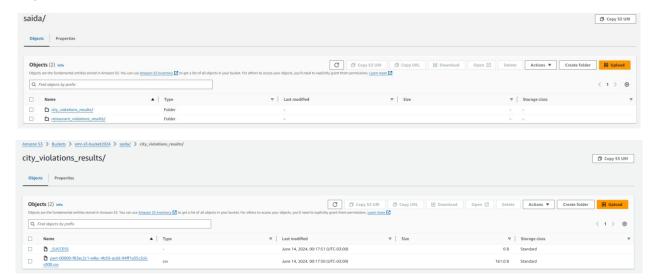
Descrição do script:

- Realiza import do SparkSession
- Função: calculate_red_violations
 - Essa função recebe o valor de data_source, output_uri
 - Inicia o SparkSession e verifica se data source não é vazio. Se verdadeiro, carrega os arquivos CSV.
 - Cria DataFrame na mémoria para realizar consulta. DataFrames restaurants_df e city_df
- Cria dois novos DataFrames a partir de consultas utilizando 'spark.sql', calculando os 10 restaurantes/cidades com mais violações do tipo RED.
 - Salva os resultados das consultas nos paths:
 - -- output uri = 's3://emr-s3-bucket2024/saida/restaurant violations results'
 - -- output_uri_city = 's3://emr-s3-bucket2024/saida/city_violations_results'





4. Ao rodar script, é criado um ID e YARN App ID. Abaixo vemos a confirmação da criação que os diretórios e arquivos CSVs foram criados com os resultados das consultas.



5. Resultado de **Restaurantes** com maiores violações do tipo RED:

4	Α	В	C
1	name	total_red_violations	
2	T-MOBILE PARK	416	
3	SUBWAY	327	
4	WHOLE FOODS MARKET	314	
5	PCC COMMUNITY MARKETS	272	
6	TACO TIME	196	
7	SAFEWAY INC #1508	159	
8	TAQUERIA EL RINCONSITO	154	
9	PAGLIACCI PIZZA INC	145	
10	UWAJIMAYA	139	
11	SAFEWAY STORES INC #1550	136	
12			

6. Resultado de **Cidades** com maiores violações do tipo RED:

4			
2	4	Α	В
-	1	City	total_red_violations
3 4	2	SEATTLE	24481
+	3	Seattle	13060
5 6 7	4	BELLEVUE	5197
	5	KENT	3074
-	6	FEDERAL WAY	2425
+	7	RENTON	2364
	8	REDMOND	2292
-	9	KIRKLAND	2264
	10	Bellevue	1702
-	11	TUKWILA	1481
3	12		

CSV Files Results:





part-00000-60e42d92part-00000-f83ec2c1--e7b5-4ec7-8d8d-13be4bc-4b50-acdd-94ff